

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ
«Национальный исследовательский ядерный университет «МИФИ»

КУРСОВАЯ РАБОТА

на тему:

**«Прогнозирование наиболее эффективного сочетания параметров для
создания лекарственных препаратов»**

Выполнил студент (ка) группы М24-525
Бикбулатова Айгуль Ришатовна
Научный руководитель:

Москва

2025

1. Вступление и EDA

По результатам первичного анализа установили, что в датасете 1001 сэмпл и 214 признаков. Всего обнаружено 36 пропусков, которые принято решение удалить. Также удален индексный признак, который не несет для нас смысла.


Для решения задач исследования выделяем три целевые переменные:

- **IC50 (Inhibitory Concentration 50%)** — это концентрация вещества, необходимая для подавления определённого биологического процесса на 50%
- **CC50 (Cytotoxic Concentration 50%)** — это концентрация вещества, при которой погибает 50% клеток в культуре (цитотоксический эффект)
- **SI (Селективный индекс)** — показатель селективности действия вещества: во сколько раз выше концентрация вещества, при которой оно становится токсичным для клеток, по сравнению с концентрацией, при которой оно эффективно действует на целевую мишень.

	Unnamed: 0	IC50, mM	CC50, mM	SI
count	1001.000000	1001.000000	1001.000000	1001.000000
mean	500.000000	222.805156	589.110728	72.508823
std	289.108111	402.169734	642.867508	684.482739
min	0.000000	0.003517	0.700808	0.011489
25%	250.000000	12.515396	99.999036	1.433333
50%	500.000000	46.585183	411.039342	3.846154
75%	750.000000	224.975928	894.089176	16.566667
max	1000.000000	4128.529377	4538.976189	15620.600000

Видим, что во всех трех таргетах максимальные значения значительно больше 75-го перцентиля, что скорее всего говорит о присутствии выбросов. Так как у целевых переменных наблюдается высокая размерность, при обучении потребуется проводить стандартизацию данных.

Рассмотрим распределение целевых переменных.



Видим, что распределение всех трех целевых показателей похоже на лог-нормальное с большим количеством околонулевых значений и длинным правым «хвостом». Учтем это при обучении моделей.

Графики «ящик с усами» по трем переменным подтверждает, что в данных имеются выбросы. В итоговых датасетах после подготовки и обработки осталось по 150 признаков.

2. Задачи регрессии

2.1. Регрессия для IC50

IC50 - это концентрация вещества, необходимая для подавления определённого биологического процесса на 50%.

По условиям задачи нам было нужно построить модели регрессии, предсказывающие значение IC50 по представленным в датасете признакам, которых после EDA осталось 150.

Для исследования использовались наиболее известные модели, подходящие для выполнения задачи: Random Forest, Gradient Boosting, XGBoost и SVR.


В качестве метрик для оценки качества предсказания выбраны MAPE, R2 и MSE с основным упором на R2.

По результатам первого эксперимента получены очень слабые метрики.


Model	MAPE	R2	MSE
Random Forest	11.1587	0.0885	9793.8543
Gradient Boosting	14.6298	0.0060	10680.4055
XGBoost	11.6592	0.0040	10702.5942
SVR	6.8800	0.1883	8722.2227

Так как в ходе EDA мы заметили лог-нормальность распределения данных, решено пробовать проводить обучение и оценку признаков-логарифмов. Для «прозрачности» результатов будет экспонировать метрики в обычный вид.

По результатам обучения получили следующие результаты:



В общем виде метрики еще не могут внушать доверия, но суммарно отметим преобладание метрик Градиентного бустинга на другими моделями. Попробуем дальше улучшать качество этой модели, путем перебора гиперпараметров.



В ходе исследования не смогли получить значимые и доверительные метрики (максимальное значение $R^2 = 0,18$). Не можем рассчитывать на эффективность признака IC50.

2.2. Регрессия для CC50

CC50 (Cytotoxic Concentration 50%) — это концентрация вещества, при которой погибает 50% клеток в культуре (цитотоксический эффект).

По условиям задачи нам было нужно построить модели регрессии, предсказывающие значение CC50 по представленным в датасете признакам, которых после EDA осталось 150.

Модели и метрики для признака CC50 выбраны те же, что и для признака IC50.


После первого эксперимента получили следующие оценки качества модели:

Model	MAPE	R2	MSE
Random Forest	4.4683	0.5070	113410.9879
Gradient Boosting	4.1005	0.5293	108290.4872
SVR	4.8078	0.3052	159846.5615
XGBoost	3.3850	0.4975	115598.0791

Мы получили довольно неплохой R^2 , но MAPE и MSE очень высокие — попробуем улучшить результат.

Так как в ходе EDA мы заметили лог-нормальность распределения данных, решено пробовать проводить обучение и оценку признаков-логарифмов. Для

«прозрачности» результатов будет экспонировать метрики в обычный вид. Ниже представлена визуализация распределения данных признака, которая подводит к мысли о нормальности распределения логарифмированного признака.




Распределение прологарифмированной целевой переменной действительно похоже на нормальное.

По результатам обучения на прологарифмированных данных не заметили значительного улучшения метрик:

Model	MAPE	R2	MSE
Random Forest	4.4683	0.5070	113410.9879
Gradient Boosting	4.1005	0.5293	108290.4872
SVR	4.8078	0.3052	159846.5615
XGBoost	3.3850	0.4975	115598.0791
Random Forest log-transformed	1.6214	0.3671	145587.3268
Gradient Boosting log-transformed	1.5931	0.4072	136378.7300
XGBoost log-transformed	1.6555	0.4346	130073.5628
SVR log-transformed	2.3326	-0.0613	244153.8251
XGBoost filtered	1.7206	0.3805	142517.0987
XGBoost tuned	1.6555	0.4346	130073.5628

Для всех метрик значения понизились, поэтому продолжили исследование и попытались отфильтровать «важные» признаки в датасете, а затем провести обучение на новых отфильтрованных данных.



По результатам оценки качество метрик неудовлетворительное, лучший результат показала модель Градиентного бустинга на исходных данных ($R^2 = 0,53$). Не можем строить достоверный прогноз на основе CC50.

2.3. Регрессия для SI

SI (Селективный индекс) — показатель селективности действия вещества: во сколько раз выше концентрация вещества, при которой оно становится токсичным для клеток, по сравнению с концентрацией, при которой оно эффективно действует на целевую мишень.

В качестве метрик для оценки качества предсказания так же, как и ранее, использовались MAPE, R2 и MSE с основным упором на R2.

Для рассмотрения я выбрал следующие модели: Random Forest, Gradient Boosting, XGBoost и SVR.

В первом подходе все модели запускались на полученном после EDA датасете с небольшим диапазоном гиперпараметров для подбора.

Был получен следующий результат:

Model	MAPE	R2	MSE
Random Forest	3.7035	0.0487	68.8955
Gradient Boosting	3.4010	0.1032	64.9482
XGBoost	3.5468	-0.0109	73.2086
SVR	2.2558	-0.0088	73.0541

Результаты метрик значимо слабые.

Повторяем исследование на логарифмированных данных признака.

Model	MAPE	R2	MSE
Random Forest	3.7035	0.0487	68.8955
Gradient Boosting	3.4010	0.1032	64.9482
XGBoost	3.5468	-0.0109	73.2086
SVR	2.2558	-0.0088	73.0541
Random Forest log-transformed	1414287975.0711	-674464505394333351936.0000	48844246485463686184960.0000
Gradient Boosting log-transformed	179796060.1817	-5475825086129518592.0000	396555412596279803904.0000
XGBoost log-transformed	34509433527.5096	-182969242631049362538496.0000	13250504236845599450726400.0000
SVR log-transformed	244409431.2503	-17272135082743603200.0000	1250835909917167321088.0000

У всех моделей видим значительное снижение качества моделей.


Для дальнейших попыток улучшить результат была выбрана модель Gradient Boosting, показавшая лучшие метрики среди других с использованием нелогарифмированной целевой переменной. В качестве экспериментов изменялись гиперпараметры, но высокой метрики модели добиться не удалось (лучший результат $R2 = 0.16$).

3. Задачи классификации

3.1. Превышает ли значение IC50 медианное значение выборки


Для исследования использовались модели Random Forest, XGBoost, Logistic Regression, SVM и CatBoost.

Для получения бэйзлайна модели были обучены с гиперпараметрами по умолчанию. Получен следующий результат:




Все лучшие метрики вышли у Random Forest.

Дальше попробуем подобрать гиперпараметры, максимизируя F1. Получился такой результат:



Улучшений практически нет, поэтому вернемся к параметрам по умолчанию и попробуем подобрать порог вероятности, максимизирующий F1 (порог = 0.38), и попробуем применить метод PCA.

Получили следующие результаты:



Лучший результат по Accuracy и Recall показала модель с порогом вероятности 0.38. При этом также наблюдаем повышение значений в Precision и F1.


Лучший результат показала модель Random Forest(макс.метрика 0.89), что уже позволяет судить о возможном применении классификации IC50.

3.2. Классификация: превышает ли значение CC50 медианное значение выборки

Для исследования использовали модели Random Forest, XGBoost, Logistic Regression, SVM и CatBoost.

После разделения датасета на тренировочный и тестовый, в тренировочном была найдена медиана и именно относительно этого значения проводилась классификация.

Для получения бэйзлайна модели были обучены с гиперпараметрами по умолчанию. Получен следующий результат:




Суммарно по метрикам лучший результат показала модель XGBoost, будем продолжать работу с ней, максимизируя F1.

```
Test Accuracy: 0.7616580310880829
Test Precision: 0.7254901960784313
Test Recall: 0.8043478260869565
Test F1: 0.7628865979381443
```

Модель получила немного больший Recall, но за счет снижения остальных метрик. Вернемся к параметрам по умолчанию и попробуем подобрать порог вероятности, максимизирующий F1 (порог = 0.44), а также подобрать его с помощью ROC (0.44). Также попробуем применить метод PCA.

Сравнительный анализ дает следующие результаты:



Лучший результат получили на нефильтрованных данных с моделью SVM (0.83). Максимизирование метрики F1 помогает увеличить качество, но незначительно для задачи.

3.3. Классификация: превышает ли значение SI медианное значение выборки

Используем следующие модели: Random Forest, XGBoost, Logistic Regression, SVM и CatBoost.

После разделения датасета на тренировочный и тестовый, в тренировочном была найдена медиана и именно относительно этого значения проводилась классификация.

	Model	CV Accuracy	CV Precision	CV Recall	CV F1
1	XGBoost	0.5929	0.6002	0.5743	0.5827
4	CatBoost	0.6000	0.6079	0.5857	0.5931
2	Logistic Regression	0.5700	0.5728	0.5657	0.5664
0	Random Forest	0.5986	0.6059	0.5886	0.5928
3	SVM	0.5871	0.5913	0.5943	0.5882

	Test Accuracy	Test Precision	Test Recall	Test F1
1	0.6761	0.6854	0.6778	0.6816
4	0.6591	0.6596	0.6889	0.6739
2	0.6591	0.6786	0.6333	0.6552
0	0.6420	0.6517	0.6444	0.6480
3	0.6193	0.6264	0.6333	0.6298

XGBoost показала лучший результат по трем метрикам из четырех - попробуем его улучшить.

Получился такой результат:

```
Test Accuracy: 0.6761363636363636
Test Precision: 0.6853932584269663
Test Recall: 0.6777777777777778
Test F1: 0.6815642458100558
```

Изменений практически нет, поэтому попробуем подобрать порог вероятности, максимизирующий F1 (0.12), а также подобрать его с помощью ROC (0.59). Также попробуем применить метод PCA.

```
Test Accuracy: 0.6875
Test Precision: 0.7160493827160493
Test Recall: 0.6444444444444445
Test F1: 0.6783625730994152
```


По результатам можем отметить повышение Precision и небольшое по F1, но результат получен за счет снижения Recall.

3.4. Классификация: превышает ли значение SI значение 8


Используем модели Random Forest, XGBoost, Logistic Regression, SVM и CatBoost.

К сожалению, условия задачи не конкретизируют, какие значения критичны и ошибки какого рода нам важнее, поэтому будем максимизировать метрики F1 и Recall как наиболее общие.

Для начала посмотрим на распределение целевой переменной.




Видим, что большинство значений расположено в диапазоне от 0 до 10, есть выбросы в правой части датасета. Для балансировки данных используем RandomOverSampler.




Для получения бэйзлайна модели были обучены с гиперпараметрами по умолчанию. Получен следующий результат:

	Model	CV Accuracy	CV Precision	CV Recall	CV F1	Test Accuracy
0	Random Forest	0.8612	0.8287	0.9203	0.8703	0.6761
	Test Precision	Test Recall	Test F1			
0		0.4038	0.4468	0.4242		




Лучшие результаты по вышли у Random Forest и Catboost - далее будем пробовать улучшить эти модели.

Попробуем подобрать гиперпараметры, максимизируя F1. Получился такой результат:



Модель стала лучше предсказывать по Accuracy и Precision, но целевые метрики снизились - попробуем подобрать порог вероятности, максимизирующий F1 (0.74), а также подобрать его с помощью ROC (также 0.75).

Получили следующие результаты:



Модели со смещенным порогом вероятностей показали одинаковые результаты – у них самые высокие метрики F1 и Recall, но немного ниже Accuracy и Precision/