

Аналитический отчет

Цель исследования:

Построение и сравнение моделей регрессии и бинарной классификации для трех целевых переменных: IC50, CC50 и SI.

Выбор наиболее подходящей модели для дальнейшей эксплуатации.

Входные данные:

Датасеты из файла Данные_для_курсовой_Классическое_MO.xlsx

Всего 1000 записей и 214 признаков.

Ход исследования:

1. Предварительная обработка данных:

Удалены неинформативные столбцы и заполнены пропуски (NaN-значения заменены нулями).

Произведено удаление экстремальных значений (выбросов) для каждой целевой переменной (IC50, CC50, SI).

2. Постановка задачи:

Основная задача: создание моделей регрессии и бинарной классификации для указанных целевых переменных.

Для регрессии использовались следующие модели: Линейная регрессия, Решающее дерево, Случайный лес, Нейронная сеть (MLP), SVM.

Для бинарной классификации использовали аналогичные модели: Логистическая регрессия, Решающее дерево, Случайный лес, Нейронная сеть (MLP), SVM.

3. Методология:

Производилось обучение моделей с применением GridSearchCV для оптимального подбора гиперпараметров.

Применялись три подхода к снижению размерности: Без снижения, PCA (главные компоненты), UMAP (нелинейное сокращение размерности).

Критерии оценки моделей: точность (accuracy), полнота (recall), F1-метрика, ROC-AUC, коэффициент детерминации (R²).

4. Результаты:

Среди моделей регрессии выделяется Случайный лес (RandomForest), демонстрируя положительные значения метрики R².

Большинство моделей показывают низкие значения R^2 (<0.4), что указывает на необходимость доработки или введения новых признаков.

В задачах бинарной классификации также лидирует Решающее дерево (DecisionTree).

5. Влияние размера датасета:

Уменьшение объема данных (до 50–60% первоначального объема) практически не ухудшает качество моделей.

Удаление выбросов заметно повышает стабильность и снижает риск переобучения.

6. Заключение:

Наиболее эффективные модели: Случайный лес (RandomForest) для регрессии, Решающее дерево (DecisionTree) для бинарной классификации.

Необходимо дальнейшее расширение признаков и углубленное исследование зависимости целевых переменных от прочих признаков.

Основные выводы:

Для работы с данными, имеющими слабые зависимости между признаками, рекомендуется применять разные семейства моделей с оптимальным подбором параметров.

Минимальный объем данных (около 500 записей) необходим для успешного обучения.

Эффективность применения методов снижения размерности ограничена и может снизить качество моделей.